



Universidade do Minho

Escola de Engenharia

Mestrado em Inteligência Artificial

Computação Inspirada na Natureza

Aplicação de Algoritmos Evolutivos Multiobjetivo para a Otimização de Rotas de Transporte Urbano no Grande Porto

Eduardo Vilaça - PG60252

Nuno Ni - PG60285

Pedro Gomes - PG60289

Tiago Moreira - PG58900

2025-2026

- 1 Introdução
- 2 Modelação do Problema
- 3 Metodologia: MOEA/D
- 4 Análise de Resultados
- 5 Conclusão

A mobilidade no Grande Porto é um sistema complexo onde a escolha da "melhor rota" não é linear. Os sistemas tradicionais focam-se apenas no tempo e distância, ignorando fatores ambientais e de saúde.

Conflito de Objetivos

- **STCP (Autocarro):** Elevada capilaridade, mas sujeito a trânsito e elevada pegada carbónica.
- **Metro:** Rápido e ecológico, mas cobertura geográfica limitada.
- **Caminhada:** Frequentemente vista como custo, mas representa um ganho em saúde.

Objetivos do Projeto

- 1 Modelar a rede real usando dados **GTFS**.
- 2 Resolver o conflito **Tempo vs. CO₂** usando Computação Evolutiva.
- 3 Oferecer um leque de soluções (**Frenteira de Pareto**).

Construção do Grafo Multimodal (GTFS)

O sistema processa ficheiros *General Transit Feed Specification* para construir um grafo direcionado $G = (V, E)$.

1. Tratamento de Dados

- **Nós (V):** Fusão de paragens STCP e Metro.
- **Arestas de Transporte (E_t):** Pesos calculados pela diferença temporal ($t_{chegada} - t_{partida}$).
- **Normalização:** Conversão de horários GTFS "25:30:00" para segundos absolutos.

2. Conectividade

- **Desafio:** Ligar paragens fisicamente próximas mas logicamente separadas.
- **Solução:** Implementação de uma **KDTree** (Partição Espacial).
- Permite pesquisas de vizinhança em $O(\log N)$, criando arestas "A Pé" para nós a $< 300m$.

Formulação Matemática dos Objetivos

O problema é modelado como a minimização do vetor $F(x) = (f_1(x), f_2(x))$:

Obj 1: Minimizar Tempo (f_1)

$$f_1(x) = \sum_{(u,v) \in x} t_{uv} + \sum \text{Penalizações}$$

Inclui penalização suave (5 min) por transbordo para evitar fragmentação excessiva.

Obj 2: Minimizar CO_2 (f_2)

$$f_2(x) = \sum_{(u,v) \in x} d_{uv} \times E_{modo}$$

- Metro: $40.0 \text{ gCO}_2/\text{km}$
- STCP: $109.9 \text{ gCO}_2/\text{km}$
- A Pé: 0 gCO_2

Restrição Rígida (Hard Constraint): Se o tempo total de caminhada > 60 min, a solução é considerada inviável.

O Algoritmo MOEA/D

Optou-se pelo **MOEA/D** (*Based on Decomposition*) devido à sua eficácia em problemas combinatórios complexos.

Decomposição

- O problema multiobjetivo é decomposto em $N = 40$ subproblemas escalares.
- Cada subproblema i tem um vetor de pesos $\lambda^i = (\lambda_t, \lambda_c)$.
- Resolve-se tudo simultaneamente numa única população.

Função de Escalarização (Tchebycheff):

$$g^{te}(x|\lambda, z^*) = \max_{j \in \{1,2\}} \{\lambda_j |f_j(x) - z_j^*|\}$$

Permite encontrar soluções mesmo em fronteiras de Pareto não-convexas, ao contrário da Soma Ponderada simples.

A inicialização aleatória em grafos esparsos gera caminhos desconexos. Foram implementadas estratégias específicas para garantir a validade das rotas.


1. Inicialização Híbrida (Dijkstra)

- Para cada subproblema, gera-se o indivíduo inicial usando Dijkstra com custos ponderados:
$$C = \lambda_t f_1 + \lambda_c f_2.$$
- Garante diversidade inicial e soluções válidas na Geração 0.

2. Mutação Topológica


- Seleciona dois nós aleatórios na rota (v_a, v_b) e remove o segmento intermédio.
- Reconecta usando o caminho mais curto no grafo.
- **Efeito:** O algoritmo aprende "atalhos" e trocas modais inteligentes.

Fluxograma da Implementação



Fronteira de Pareto

Resultados obtidos com uma população de 40, 100 gerações, taxa de mutação de 40% e penalização de +500 minutos para caminhos com excesso de caminhada (> 60 min.) e +5 minutos por cada transbordo.



Análise do Trade-off:

- **Curva Convexa:** Evidência clara do conflito entre objetivos.
- **Extremo Rápido:** Predomínio de STCP (linhas diretas), emissões elevadas.
- **Extremo Ecológico:** Combinação Metro + Caminhada, emissões reduzidas.
- **Região Central:** Soluções de compromisso (Multimodais).

Figura: Fronteira de Pareto com dificuldade média (entre 50 a 100 passos do grafo)

Fronteira de Pareto

Exemplos com dificuldade difícil e fácil.




Figura: Fronteira de Pareto com dificuldade difícil (100 a 200 passos)




Figura: Fronteira de Pareto com dificuldade fácil (15 a 50 passos)

Visualização das Rotas

O sistema gera um mapa vetorial das rotas, destacando o meio de transporte, tempo e kcal gastas ou distância percorrida.




Figura: Rotas do exemplo de dificuldade média (50 a 100 passos)

Apresentação explícita de Kcal gastas nos segmentos a pé, transformando o transbordo ou um percurso a pé num benefício.

Visualização das Rotas




Figura: Rotas com dificuldade difícil (100 a 200 passos)




Figura: Rotas com dificuldade fácil (15 a 50 passos)

Estudo de Caso Comparativo

Para uma viagem representativa (ex: Boavista $\rightarrow$ Trindade), o algoritmo oferece opções distintas:

Métrica	Opção A (Rápida)	Opção B (Ecológica)	Variação
Modo Princ.	STCP Direto	Metro + Pé	-
Tempo	25 min	42 min	+68%
Emissões	850 g	120 g	-85%
Calorias	15 kcal	120 kcal	+700%

Tabela: Comparação de trade-offs reais.

Conclusão: O sistema permite ao utilizador "trocar" tempo por sustentabilidade e saúde de forma consciente.

Síntese:

- 1 A integração de dados GTFS e KDTrees permitiu modelar realisticamente a rede do Porto.
- 2 A inicialização híbrida foi crítica para o sucesso do MOEA/D em grafos esparsos.
- 3 Não existe uma "melhor rota" universal: o sistema ajuda o utilizador a decidir com base nas suas prioridades (Tempo vs Ambiente vs Saúde).

Limitações e Futuro:

- Integração de dados em Tempo Real (APIs) para mitigar atrasos.
- Inclusão da Topografia (relevo acidentado do Porto) para cálculo preciso do esforço físico.

- [1] Q. Zhang and H. Li.
MOEA/D: A Multiobjective Evolutionary Algorithm Based on Decomposition.
IEEE Trans. Evol. Comput., 11(6), 2007, pp. 712–731.
- [2] K. Deb.
Multi-Objective Optimization using Evolutionary Algorithms.
John Wiley & Sons, 2001.
- [3] Google Developers.
GTFS Reference.
Google Transit APIs, 2024.
<https://developers.google.com/transit/gtfs>.
- [4] A. Hagberg et al.
Exploring network structure using NetworkX.
SciPy2008, 2008, pp. 11–15.
- [5] Porto Digital.
Infraestruturas e Mobilidade (GTFS).
Portal de Dados Abertos, 2024.
- [6] E. W. Dijkstra.
A note on two problems in connexion with graphs.
Numerische Mathematik, 1(1), 1959.
- [7] J. L. Bentley.
Multidimensional binary search trees.
Comm. of the ACM, 18(9), 1975.
- [8] C. Coello et al.
Evolutionary Algorithms for Solving Multi-Objective Problems.
Springer, 2007.
- [9] W. McKinney.
Data Structures for Statistical Computing in Python.
SciPy2010, 2010.
- [10] EEA.
Transitions towards a more sustainable mobility system.
EEA Report No 34/2016.

Eduardo Vilaça - PG60252 $\Delta = 0$
Nuno Ni - PG60285 $\Delta = -0.5$
Pedro Gomes - PG60289 $\Delta = 1$
Tiago Moreira - PG58900 $\Delta = -0.5$