



Universidade do Minho
Escola de Engenharia

UNIVERSIDADE DO MINHO

MESTRADO EM INTELIGÊNCIA ARTIFICIAL

Computação Inspirada na Natureza

**Aplicação de Algoritmos Evolutivos
Multiobjetivo para a Otimização de Rotas de
Transporte Urbano no Grande Porto**

Eduardo Vilaça - PG60252

Nuno Ni - PG60285

Pedro Gomes - PG60289

Tiago Moreira - PG58900

2025-2026

Resumo

O planeamento de rotas em ambientes urbanos complexos é um problema desafiante que envolve frequentemente objetivos conflituosos, como a minimização do tempo de viagem e a redução da pegada ecológica. Este projeto aborda a otimização de rotas multimodais na Área Metropolitana do Porto, integrando as redes de Metro do Porto e STCP (autocarros) num grafo unificado. Utilizando dados reais em formato GTFS, foi construído um modelo de rede que conecta milhares de paragens através de transbordos a pé, eficientemente calculados com recurso a estruturas de dados espaciais (KDTrees). Para resolver o problema de otimização multiobjetivo, foi implementado o algoritmo evolutivo MOEA/D (Multi-Objective Evolutionary Algorithm based on Decomposition), utilizando a decomposição de Tchebycheff e uma inicialização heurística baseada em Dijkstra para acelerar a convergência. Os resultados demonstram a capacidade do sistema em gerar uma Fronteira de Pareto robusta, oferecendo ao utilizador um leque de soluções não dominadas que variam entre rotas rápidas e rotas sustentáveis, contemplando ainda a componente de exercício físico através da caminhada.

Palavras-chave: Otimização Multiobjetivo, Algoritmos Evolutivos, MOEA/D, Transporte Multimodal, GTFS, Sustentabilidade, Exercício Físico.

Conteúdo

1	Introdução	4
1.1	Enquadramento e Motivação	4
1.2	Objetivos	4
2	Modelação do Problema	5
2.1	Aquisição e Tratamento de Dados (GTFS)	5
2.2	Construção do Grafo Multimodal	5
2.2.1	Definição dos Nós	5
2.2.2	Arestas de Transporte	5
2.2.3	Modelação de Transbordos a Pé (Algoritmo KDTree)	6
2.2.4	Formulação dos Objetivos e Restrições	6
3	Metodologia: O Algoritmo MOEA/D	8
3.1	Decomposição do Problema	8
3.1.1	Função de Escalarização (Tchebycheff)	8
3.2	Representação e Inicialização Heurística	8
3.2.1	Inicialização Inteligente (Dijkstra Híbrido)	8
3.3	Operadores Evolutivos	9
3.4	Arquivo Externo e Seleção Final	9
4	Análise de Resultados	11
4.1	Configuração Experimental	11
4.2	Análise de Fronteira de Pareto	11
4.3	Visualização Detalhada das Rotas	12
4.4	Configuração Adicional	13
5	Conclusão e Trabalho Futuro	14
5.1	Síntese do Trabalho Desenvolvido	14
5.2	Conclusões principais	14
5.3	Limitações e Trabalho Futuro	15

1 Introdução

A mobilidade urbana é um dos pilares fundamentais das cidades inteligentes e sustentáveis, no entanto, a escolha do melhor trajeto entre dois pontos deixou de ser uma questão fácil focada apenas na rapidez. Atualmente, os cidadãos procuram equilibrar a eficiência temporal com a consciência ambiental e o bem-estar físico. No Grande Porto, a coexistência de diferentes modos de transporte (Metro e Autocarro) cria uma rede complexa onde a rota mais rápida nem sempre é a mais ecológica ou a mais económica.

Este projeto, propõe uma solução computacional para este problema, modelando-o como um problema de otimização combinatória multiobjetivo.

1.1 Enquadramento e Motivação

Os sistemas de navegação tradicionais tendem a fornecer uma única solução "ótima" baseada no tempo, contudo em cenários reais, os objetivos são frequentemente contraditórios:

- **Tempo vs. CO_2 :** O transporte rodoviário (autocarro) pode oferecer ligações diretas e rápidas, mas possui uma taxa de emissões de CO_2 significativamente superior à do Metro.
- **Conforto vs. Saúde:** Minimizar o esforço físico (caminhada) opõe-se ao objetivo de promover um estilo de vida saudável e ativo.

A motivação deste trabalho reside na necessidade de fornecer aos utilizadores ferramentas de decisão que explicitem estes compromissos (trade-offs), permitindo escolhas informadas alinhadas com as suas prioridades pessoais.

1.2 Objetivos

O objetivo principal é desenvolver um sistema de recomendação de rotas capaz de encontrar a Fronteira de Pareto para viagens no Grande Porto. Os objetivos específicos incluem:

- **Integração de Dados Reais:** Processamento de ficheiros GTFS (General Transit Feed Specification) da STCP e Metro do Porto para construir um grafo multimodal realista.
- **Modelação de Conexões:** Implementação de uma estratégia eficiente para modelar transbordos a pé entre paragens distintas, garantindo a conectividade da rede
- **Aplicação de Computação Evolutiva:** Implementação e adaptação do algoritmo MOEA/D para explorar o espaço de soluções, decompondo o problema em subproblemas escalares com diferentes pesos para Tempo e Sustentabilidade.
- **Análise de Cenários:** Avaliação das soluções geradas em termos de tempo total, emissões de gases de efeito estufa e calorias gastas.

2 Modelação do Problema

A representação computacional de uma rede de transportes urbanos é um passo crítico para a aplicação eficaz de algoritmos de otimização. Este capítulo descreve a metodologia utilizada para transformar os dados brutos dos operadores de transporte num modelo de grafo multimodal, bem como a formulação matemática dos objetivos e restrições.

2.1 Aquisição e Tratamento de Dados (GTFS)

O projeto utiliza dados reais fornecidos pela Metro do Porto e pela STCP (Sociedade de Transportes Coletivos do Porto) no formato padrão GTFS (General Transit Feed Specification). Este formato descreve horários e informações geográficas através de ficheiros de texto relacionais.

Foram processados os seguintes ficheiros principais:

- `stops.txt`: Localização geográfica (latitude/longitude) das paragens e estações.
- `stop_times.txt`: Horários de chegada e partida em cada paragem.
- `trips.txt`: Definição das viagens e associação às rotas.

Um dos desafios técnicos abordados foi a normalização dos dados temporais, uma vez que o formato GTFS permite representações de horas superiores a 24:00:00 (para viagens que passam da meia-noite). Foi implementada uma função de parsing robusta para converter estes valores numa escala linear de segundos, permitindo cálculos de duração precisos.

2.2 Construção do Grafo Multimodal

O sistema de transportes foi modelado como um grafo direcionado $G = (V, E)$, onde V representa o conjunto de nós (paragens) e E o conjunto de arestas (ligações).

2.2.1 Definição dos Nós

Cada paragem ou estação foi mapeada para um nó no grafo. Para evitar conflitos de identificadores entre operadores distintos (ex: IDs numéricos idênticos na STCP e Metro), foi aplicado um pré-processamento para criar identificadores únicos compostos (e.g., `metro_Trindade` vs `stcp_Trindade`).

2.2.2 Arestas de Transporte

As conexões via transporte público foram geradas iterando sobre as sequências de paragens definidas no ficheiro `stop_times.txt`. Para cada par de paragens consecutivas (u, v) numa viagem, foi criada uma aresta direcionada com os seguintes atributos:

- **Peso Temporal (w_t):** A diferença entre o horário de chegada em v e o horário de partida de u .
- **Emissões de CO_2 (w_c):** Calculadas com base na distância real percorrida. Diferente de abordagens simplistas que usam custos fixos, este projeto calcula a distância geodésica (fórmula de Haversine) $d(u, v)$ entre as coordenadas das paragens. O custo ambiental é dado por:

$$CO_2(u, v) = d(u, v) \times \text{Taxa de Emissão}_{modo}$$

- Taxa Metro: $40.0 \text{ gCO}_2/\text{km}$
- Taxa STCP: $109.9 \text{ gCO}_2/\text{km}$

2.2.3 Modelação de Transbordos a Pé (Algoritmo KDTree)

Um desafio central em redes multimodais é conectar paragens fisicamente próximas mas logicamente separadas (ex: sair do Metro na Casa da Música e caminhar para a paragem de autocarro). Dada a dimensão da rede, uma abordagem de força bruta $O(N^2)$ para verificar a proximidade entre todas as paragens seria computacionalmente inviável. Para resolver isto, utilizou-se uma KDTree (k-dimensional tree), uma estrutura de dados de partição espacial. Isto permitiu realizar consultas de proximidade eficientes. Foram criadas arestas bidirecionais de "caminhada" entre nós com distância geográfica inferior a 300 metros.

- **Custo Temporal:** $\frac{\text{Distância}}{5\text{km/h}}$.
- **Emissões:** 0 gCO_2 .

2.2.4 Formulação dos Objetivos e Restrições

O problema de otimização visa encontrar um caminho x que minimize simultaneamente dois objetivos conflituosos:

- Minimizar o Tempo Total (f_1):

$$f_1(x) = \sum_{(u,v) \in x} \text{Tempo}(u, v) + \text{Penalizações}$$

- Minimizar as Emissões de CO_2 (f_2):

$$f_2(x) = \sum_{(u,v) \in x} CO_2(u, v) + \text{Penalizações}$$

Para garantir a qualidade e realismo das soluções, foram implementadas penalizações na função de avaliação (Fitness):

- **Penalização de Transbordo:** Adiciona-se um custo virtual (5 minutos) sempre que ocorre uma mudança de trip_id, desencorajando rotas com trocas excessivas.
- **Limite de Caminhada (Hard Constraint):** Se o tempo acumulado a pé numa rota exceder 60 minutos (configurável), é aplicada uma penalização severa (+500 minutos), tornando a solução inviável para efeitos de seleção, a menos que não existam alternativas.

3 Metodologia: O Algoritmo MOEA/D

Este capítulo detalha a abordagem algorítmica adotada para resolver o problema de otimização de rotas. Dado o carácter multiobjetivo do problema (conflito entre Tempo e CO_2), optou-se pela utilização do MOEA/D (Multi-Objective Evolutionary Algorithm based on Decomposition). Ao contrário dos algoritmos genéticos clássicos que utilizam mecanismos de dominância (como o NSGA-II), o MOEA/D decompõe o problema principal em vários subproblemas escalares de otimização, resolvendo-os simultaneamente. Esta abordagem é particularmente eficaz em problemas combinatórios complexos, pois permite manter a diversidade da população e convergir eficientemente para a Fronteira de Pareto.

3.1 Decomposição do Problema

O princípio central do MOEA/D é a transformação do vetor de objetivos $F(x) = (f_1(x), f_2(x))$ num conjunto de N problemas escalares. Foram definidos $N = 40$ subproblemas. Para cada subproblema i (onde $i = 1, \dots, N$), foi atribuído um vetor de pesos $\lambda^i = (\lambda_t^i, \lambda_c^i)$, tal que $\lambda_t^i + \lambda_c^i = 1$. Estes pesos foram distribuídos uniformemente, variando desde uma prioridade total no tempo ($\lambda_t = 1, \lambda_c = 0$) até uma prioridade total na sustentabilidade ($\lambda_t = 0, \lambda_c = 1$).

3.1.1 Função de Escalarização (Tchebycheff)

Para avaliar a qualidade de uma solução num subproblema específico, utilizou-se a abordagem de Tchebycheff, que minimiza a distância ponderada máxima até um ponto de referência ideal z^* :

$$g^{te}(x|\lambda, z^*) = \max_{j \in \{1,2\}} \{\lambda_j |f_j(x) - z_j^*|\}$$

Onde $z^* = (z_1^*, z_2^*)$ representa o "Ponto Ideal" (os melhores valores de tempo e CO_2 encontrados até ao momento em toda a população). Esta função é superior à soma ponderada simples pois consegue encontrar soluções em frentes de Pareto não convexas.

3.2 Representação e Inicialização Heurística

Num problema de rotas (routing), a representação cromossómica tradicional (cadeia de bits) é ineficiente. Neste projeto, uma solução é representada diretamente como uma lista ordenada de identificadores de nós: $x = [v_{origem}, v_1, v_2, \dots, v_{destino}]$

3.2.1 Inicialização Inteligente (Dijkstra Híbrido)

A inicialização aleatória em grafos de transporte de grande dimensão gera frequentemente rotas inválidas ou excessivamente longas. Para contornar este problema e acelerar a convergência, foi implementada uma inicialização heurística baseada no algoritmo de Dijkstra. Para cada um

dos N subproblemas, a população inicial foi gerada executando o Dijkstra com uma função de custo composta pelos pesos do subproblema:

$$Custo(u, v) = \lambda_t^i \times Tempo(u, v) + \lambda_c^i \times CO_2(u, v)$$

Isto garante que, na Geração 0, a população já contém soluções otimizadas localmente para diferentes trade-offs, cabendo ao algoritmo evolutivo apenas o refinamento e a exploração de alternativas através de mutação.

3.3 Operadores Evolutivos

Dada a restrição topológica do grafo (a necessidade de manter um caminho contínuo), o operador de cruzamento (crossover) tradicional pode gerar rotas desconexas. Assim, o processo evolutivo focou-se na Mutação. O operador seleciona dois nós aleatórios na rota atual, v_a e v_b , e remove o segmento intermédio. De seguida, calcula um novo sub-caminho entre v_a e v_b utilizando o caminho mais curto no grafo. Este processo introduz variabilidade, permitindo ao algoritmo descobrir atalhos ou desvios que favoreçam um dos objetivos (ex: trocar um segmento de autocarro por um de metro).

3.4 Arquivo Externo e Seleção Final

Durante o processo evolutivo (configurado para 100 gerações), todas as soluções geradas que não violam as restrições (limite de caminhada e penalizações) são armazenadas. No final da execução, são filtradas para extrair a Fronteira de Pareto real. Uma solução x é mantida apenas se não for dominada por nenhuma outra solução y . Diz-se que x é dominada por y se:

1. y não é pior que x em nenhum objetivo;
2. y é estritamente melhor que x em pelo menos um objetivo.

Este processo resulta num conjunto final de soluções ("Menu de Opções") que é apresentado ao utilizador, classificado por tempo, emissões e exercício físico.

Ilustramos o fluxograma do algoritmo implementado:




Figura 1: Fluxograma do Algoritmo MOEA/D

4 Análise de Resultados

Este capítulo apresenta a avaliação experimental do sistema de otimização desenvolvido. Os testes foram realizados utilizando a rede completa do Grande Porto (STCP e Metro), focando-se na capacidade do algoritmo MOEA/D em gerar uma Fronteira de Pareto diversificada e na análise qualitativa das rotas sugeridas. Para cada teste é possível configurar a dificuldade para fácil (15 a 50 passos), médio (50 a 100 passos) e difícil (100 a 200 passos).

4.1 Configuração Experimental

Para validar a solução, foram definidos cenários de teste com origem e destino em zonas de alta densidade da rede, garantindo a existência de múltiplas alternativas de transporte.

Os parâmetros utilizados na execução do algoritmo evolutivo foram:

- **Dimensão da População (N):** 40 subproblemas (vetores de peso).
- **Número de Gerações:** 100 iterações.
- **Taxa de Mutação:** 40% (probabilidade de alteração de um indivíduo a cada geração).
- **Penalização:** +500 minutos para caminhos com excesso de caminhada (> 60 min.) e +5 minutos por cada transbordo.

4.2 Análise de Fronteira de Pareto

A Figura 2 ilustra a distribuição das soluções finais no espaço de objetivos (Tempo $\times$ Emissões de CO_2) para um exemplo de dificuldade média (entre 50 a 100 passos do grafo).




Figura 2: Fronteira de Pareto

4.3 Visualização Detalhada das Rotas

Para além da análise estatística, o sistema oferece uma representação topológica detalhada das soluções, conforme ilustrado na figura, para o exemplo anterior obtemos:




Figura 3: Grafo das Rotas

Na representação é possível identificar o ponto de partida a verde e o de chegada a vermelho. Cada aresta é legendada com:

- Modo de transporte (A Pé, Metro ou autocarro STCP)
- Tempo de cada percurso
- Kcal gastas se for a pé ou distância percorrida nos outros casos

Tem ainda uma legenda de identificação de cada rota, o tempo e CO_2 total gastos e o tempo | kcal total gastos a pé nessa rota.

4.4 Configuração Adicional

Um dos objetivos da nossa análise de resultados foi ser o mais personalizável possível, dado isto quisemos incluir um ficheiro com todas as configurações possíveis que, para além das acima mencionadas, tenham também impacto relevante na solução, sendo essas as seguintes:

- Gasto de CO₂ por Km percorrido de Metro (40.0 gCO₂/P.km);
- Gasto de CO₂ por Km percorrido de Autocarro (109.9 gCO₂/P.km);
- Velocidade da pessoa a pé em Km/H (5.0 Km/H);
- Distância máxima a pé entre paragens (300 metros);
- Kcal queimadas por minuto a andar (4.0 Kcal);

5 Conclusão e Trabalho Futuro

Este projeto teve como objetivo principal o desenvolvimento de um sistema de planeamento de rotas multimodais para a Área Metropolitana do Porto, capaz de resolver o conflito entre a rapidez de deslocação e a sustentabilidade ambiental. Através da aplicação de técnicas de Computação Inspirada na Natureza, especificamente o algoritmo evolutivo MOEA/D, foi possível criar uma ferramenta que não se limita a devolver um único caminho, mas um leque de opções que suportam o utilizador na sua tomada de decisão.

5.1 Síntese do Trabalho Desenvolvido

O desenvolvimento do sistema assentou em três pilares fundamentais, cuja integração constitui o principal contributo técnico deste trabalho:

- **Modelação Realista da Rede:** A utilização de dados abertos no formato GTFS (General Transit Feed Specification) permitiu construir um grafo de grande escala que reflete fielmente a complexidade da rede de transportes do Porto. A implementação de uma KD-Tree para a geração dinâmica de transbordos a pé provou ser uma solução eficiente para conectar as redes de Metro e STCP, ultrapassando o desafio computacional de processar milhares de paragens.
- **Otimização Evolutiva:** O algoritmo MOEA/D demonstrou ser uma escolha adequada para este problema combinatório. A estratégia de inicialização híbrida, combinando a aleatoriedade dos algoritmos genéticos com a eficiência do algoritmo de Dijkstra nas primeiras gerações, foi decisiva para garantir a convergência rápida para soluções viáveis num espaço de busca vasto e esparso.
- **Visualização Centrada no Utilizador:** O sistema final distingue-se pela clareza da informação apresentada. Tanto a Fonteira de Pareto como a representação gráfica das rotas, com etiquetas que acompanham as linhas e a inclusão de métricas de saúde (calorias gastas), transformam dados complexos em insights acionáveis para o utilizador.

5.2 Conclusões principais

A análise dos resultados experimentais permite retirar conclusões importantes sobre a mobilidade no Grande Porto:

- **Inexistência de uma Solução Única:** Os resultados confirmam que a "melhor rota" é subjetiva. Enquanto o autocarro (STCP) oferece frequentemente a solução mais rápida para distâncias médias, o Metro domina claramente no eixo da sustentabilidade, com emissões de CO_2 por quilómetro cerca de 60% inferiores.

- **O Valor da Intermodalidade:** As soluções de compromisso encontradas na "barriga" da Fronteira de Pareto demonstram que combinar modos de transporte (ex: Metro para a longa distância + Autocarro/Caminhada para a curtas deslocações) resulta frequentemente num equilíbrio ideal entre tempo e emissões.
- **A Caminhada como Benefício:** Ao explicitar o gasto calórico nas rotas, o sistema altera a perceção da caminhada, o que tradicionalmente é visto como um custo (tempo perdido no transbordo ou mesmo no percurso em si), passa a ser valorizado como um ganho em saúde, incentivando a mobilidade ativa.

5.3 Limitações e Trabalho Futuro

Apesar dos resultados promissores, identificam-se áreas para evolução futura do sistema:

- **Dados em Tempo Real:** O modelo atual é estático, baseando-se nos horários planeados. A integração de APIs de trânsito em tempo real permitiria lidar com atrasos e congestionamentos, aumentando a fiabilidade das previsões temporais.
- **Topografia e Acessibilidade:** O cálculo atual de calorias assume um terreno plano. Dada o relevo acidentado da cidade do Porto, a incorporação de modelos digitais de relevo seriam cruciais para calcular o esforço real e para sugerir rotas acessíveis a pessoas com mobilidade reduzida.
- **Interface Web/Mobile:** A migração do código para uma aplicação web ou móvel seria o passo natural para colocar esta ferramenta nas mãos dos cidadãos.

Em suma, este projeto demonstrou que a aplicação de algoritmos evolutivos a dados reais de transporte urbano é não só viável, como essencial para promover uma cidadania mais consciente, saudável e ecológica.

Referências

- [1] Q. Zhang and H. Li. MOEA/D: A Multiobjective Evolutionary Algorithm Based on Decomposition. In *IEEE Transactions on Evolutionary Computation*, vol. 11, no. 6, 2007, pp. 712–731. DOI: 10.1109/TEVC.2007.892759.
- [2] K. Deb. *Multi-Objective Optimization using Evolutionary Algorithms*. John Wiley & Sons, Chichester, UK, 2001.
- [3] Google Developers. General Transit Feed Specification (GTFS) Reference. In *Google Transit APIs*, 2024. Available online: <https://developers.google.com/transit/gtfs>.
- [4] A. A. Hagberg, D. A. Schult, and P. J. Swart. Exploring network structure, dynamics, and function using NetworkX. In *Proceedings of the 7th Python in Science Conference (SciPy2008)*, Pasadena, CA, 2008, pp. 11–15.
- [5] Porto Digital. Infraestruturas e Mobilidade (GTFS). In *Portal de Dados Abertos da Cidade do Porto*, 2024. Available online: https://opendata.porto.digital/dataset/?q=Infraestruturas+e+Mobilidade&res_format=GTFS.
- [6] E. W. Dijkstra. A note on two problems in connexion with graphs. In *Numerische Mathematik*, vol. 1, no. 1, 1959, pp. 269–271. DOI: 10.1007/BF01386390.
- [7] J. L. Bentley. Multidimensional binary search trees used for associative searching. In *Communications of the ACM*, vol. 18, no. 9, 1975, pp. 509–517. DOI: 10.1145/361002.361007.
- [8] C. A. Coello Coello, G. B. Lamont, and D. A. Van Veldhuizen. *Evolutionary Algorithms for Solving Multi-Objective Problems*. 2nd ed., Springer, New York, 2007.
- [9] W. McKinney. Data Structures for Statistical Computing in Python. In *Proceedings of the 9th Python in Science Conference*, vol. 445, 2010, pp. 51–56.
- [10] European Environment Agency. *Transitions towards a more sustainable mobility system: TERM 2016 report*. EEA Report No 34/2016, Copenhagen, 2016. Available online: <https://www.eea.europa.eu/publications/term-report-2016>.